

Projet Hackaton industriel : prévision du niveau du réservoir (WADI)

Stowe AGBESSI, Victoria BOUCHET, Mariani Karen LOCKO
KENGUE, Abdoulaye Brahim MAHAMAT, Miroslav PENKOV,
Merlin SIPAHIMALANI

sous la supervision de : Julien HAUTOT (Actemium)
et des enseignants référents : Nourdine AZZAOU, Boris
NECTOUX, Erwan SAINT LOUBERT BIE

30 avril 2026

Table des matières

- 1 Analyse exploratoire des données
- 2 Protocole de validation et métriques
- 3 ARIMAs, LSTMs et TCN
- 4 Modèle XGBoost et Optuna
- 5 Comparaison de modèles
- 6 Limites et contraintes

Table des matières

- 1 Analyse exploratoire des données
- 2 Protocole de validation et métriques
- 3 ARIMAs, LSTMs et TCN
- 4 Modèle XGBoost et Optuna
- 5 Comparaison de modèles
- 6 Limites et contraintes


Contexte

- Prédiction du niveau d'eau d'un réservoir industriel
- Données temporelles complexes (≈ 780000 observations)
- Plus de 120 variables (capteurs, actionneurs...)
- Objectif : comparer plusieurs approches de prédictions

Contexte et Description des données

Le système WADI

- Banc d'essai industriel de distribution d'eau
- Capteurs physiques (débit, pression, qualité eau)
- Actionneurs : pompes, vannes motorisées
- Supervision par système SCADA



Quelques Chiffres clés

784 571

observations

130

colonnes brutes

1 Hz

fréquence capteurs

13 ~ 14 jours

de données

Familles de variables

AIT (18) — Qualité eau**MV (20)** — Commandes vannes**LS (17)** — Alarmes**LT (4)** — Niveaux de réservoirs**FIT (5)** — Débits**P_STATUS** — État pompes

Nettoyage et Préprocessing

1 Index temporel

Problème : colonne Time = MM:SS,
sans l'heure

Solution : reconstruction via Row

Formule : Début + (Row - 1) × 1 s
→ 0 doublon d'index

2 Valeurs manquantes

4 colonnes 100% vides → **supprimées**

2 colonnes constantes → **supprimées**

NA résiduels (<0.01%) →

interpolation linéaire

Catégorielles → **forward-fill**

3 Lignes dupliquées

580 452 lignes identiques (74%)

Gel de capteur SCADA

→ Comportement normal industriel

→ **Conservées**

(régularité 1 Hz nécessaire)

784 571 lignes × 121 colonnes | 9 valeurs manquantes résiduelles | **Index temporel propre à 1 Hz**

Coupure détectée dans les données : arrêt SCADA de ~3 jours entre le 29/09 et 02/10 (saut d'environ 264 000 dans Row)

Variables cibles — Les 4 réservoirs (LT)

Statistiques descriptives


Variable	Moyenne (m)	Écart-type	Min	Max
1_LT_001_PV	56.37	8.85	38.81	71.62
2_LT_001_PV	69.77	0.65	68.51	71.55
2_LT_002_PV	75.41	3.47	65.70	82.98
3_LT_001_PV	65.17	1.22	63.96	69.17

1_LT_001_PV : forte variabilité ($\sigma = 8.85$ m) — réservoir suspect

3_LT_001_PV : variabilité faible ($\sigma = 1.22$ m) — cible bien régulée


Profil journalier : montée nocturne, consommation diurne

Profil journalier moyen — 3_LT_001_PV




Valeurs aberrantes et Corrélations

Détection des outliers (méthode IQR × 1.5)



Ces outliers sont des événements physiques réels (démarrages pompe, transitoires hydrauliques) → CONSERVÉS car informatifs pour la prédiction

Top corrélations avec 3_LT_001_PV




Commandes vannes (MCV) et boucles PID de débit (FIC) = features prioritaires pour la modélisation


Analyse en Composantes Principales (ACP)

63 variables numériques · 78 457 observations (10% échantillon) · Variables LT exclues

Variance expliquée par composante



Variance cumulée



Haute dimension : 15 composantes nécessaires pour 80% de variance → aucune structure basse-dimension dominante.

Non-linéarité confirmée par la projection PC1/PC2 : justifie le choix XGBoost et LSTM plutôt qu'une régression linéaire.

PC1 portée par les variables de débit / de boucles de consignes et commandes de vanne — cohérent avec les résultats de corrélation.

Synthèse EDA

Ce qu'on retient avant la modélisation

Index temporel

Reconstruit via Row — 0 doublon, 1 Hz propre

Données nettoyées

784 571 × 121 — 9 colonnes supprimées, 9 NA résiduels

Outliers conservés

Événements physiques réels (démarrages pompe, vannes)

Features prioritaires

FIC/MCV corrélés >0.5 avec la cible

Non-linéarité

Confirmée par ACP — justifie XGBoost/LSTM

Coupure 3 jours

29/09→02/10 à exclure des fenêtres glissantes

Table des matières

- 1 Analyse exploratoire des données
- 2 Protocole de validation et métriques
- 3 ARIMAs, LSTMs et TCN
- 4 Modèle XGBoost et Optuna
- 5 Comparaison de modèles
- 6 Limites et contraintes

Découpage des données

- 70% : entraînement
- 15% : validation
- 15% : test

Important

Respect de la temporalité (pas de data leakage)

Métriques

- RMSE (erreur quadratique)
- MAE (erreur absolue)
- R^2 (qualité de l'ajustement)
- Skill Score (vs modèle naïf)

Table des matières

- 1 Analyse exploratoire des données
- 2 Protocole de validation et métriques
- 3 ARIMAs, LSTMs et TCN**
- 4 Modèle XGBoost et Optuna
- 5 Comparaison de modèles
- 6 Limites et contraintes

Modèles étudiés

ARIMA / SARIMAX

- Modèles classiques
- AR + I + MA
- Saisonnalité (SARIMA)
- Variables exogènes (SARIMAX)

- 1 Comportement globalement additif $\Rightarrow$ pas de log retenu.
- 2 2 Stratégies : directe et STL

ETS (Holt-Winters)

- Modèle exponentiel

VARMA

- Modèle statistique multivarié
- Prédiction de plusieurs variables simultanément
- Basé sur relations linéaires

Modèles étudiés

LSTM

- Réseau récurrent
- Mémoire long terme
- Capture des dépendances temporelles
- Architecture :
 - 2 couches LSTM
 - Dropout
 - Dense en sortie

GRU

- Réseau récurrent
- Mémoire long terme
- Capture des dépendances temporelles
- Architecture :
 - 1 couches GRU
 - Dropout
 - Dense en sortie

TCN

- Réseau convolutif temporel
- Convolutions causales
- Dilatations + résidus

Résultats préliminaires

Modèle	RMSE	MAE	Skill Score
ARIMA	1.5186	0.9764	-27.81
ETS	1.5229	0.9788	-27.89

Observation

Performances très proches entre ARIMA et ETS

Résultats préliminaires

Modèles	RMSE	MAE	Skill Score
VARMA	4.93	3.06	-22.048
GRU	1.10	0.73	-2.249

Observation

Le modèle GRU surpasse le modèle de référence ARIMA (skill score positif), tandis que le VARMA présente des performances inférieures (skill score négatif).

Prédictions VARMA




Figure – Comparaison valeurs réelles vs prédictions VARMA

Prédictions GRU




Figure – Comparaison valeurs réelles vs prédictions GRU

Observation

Le modèle GRU capture mieux la dynamique des données et suit plus fidèlement les variations.

Résultat clé

Point critique

Skill Score fortement négatif sauf pour le GRU

- Moins performant qu'un modèle naïf

Interprétation

Les modèles n'apportent pas d'amélioration réelle

- Pas suffisamment stationnaire ?
- Difficulté à capturer la complexité du système (pour ARIMA et ETS)

Ouverture

- D'où : modèles de deep learning plus adaptés à comparer :
 - LSTM
 - TCN

Table des matières

- 1 Analyse exploratoire des données
- 2 Protocole de validation et métriques
- 3 ARIMAs, LSTMs et TCN
- 4 Modèle XGBoost et Optuna**
- 5 Comparaison de modèles
- 6 Limites et contraintes

3.1. Modélisation : Optuna + XGBoost

Feature engineering

- Créations de lags temporels (présent dépend du passé)
- Données splitées chronologiquement

XGBoost - Optimisation avec Optuna

- Recherche bayésienne
- Paramètres :
 - profondeur (max_depth)
 - learning rate
 - régularisation L1 / L2
 - subsampling

Objectif


Minimiser le RMSE avec early stopping

3.2. Évaluation et résultats

Résultats

- Bonne capacité à suivre la dynamique du niveau d'eau mais quelques petits ratés dans les "pics haut"
- RMSE : 0.0510
- MAE : 0.0373
- R^2 : 0.9982 (très élevé)

Resultats XGBoost + Optuna



3.3. Regard critique

Limites

- Seulement 15 trials (Optuna)
- Ressources de calcul limitées
- "Trop parfait" : Data leakage ?

Choix méthodologique

- Étude sur une seule variable
- Approche "proof of concept"

Perspectives

- Augmenter le nombre de trials (≥ 50)
- Étendre à plusieurs capteurs

Table des matières

- 1 Analyse exploratoire des données
- 2 Protocole de validation et métriques
- 3 ARIMAs, LSTMs et TCN
- 4 Modèle XGBoost et Optuna
- 5 Comparaison de modèles**
- 6 Limites et contraintes

Objectif et pipeline de comparaison

Cible

3_LT_001_PV

niveau du réservoir principal

Horizon

+10 min

fréquence : 1 mesure/seconde

Sorties

JSON + plots


métriques et diagnostics visuels

Données WADI

Préparation
fenêtres + splitModèles
testésÉvaluation
communeGraphiques
automatiques

Même pipeline pour comparer les modèles de manière équitable.
Split chronologique pour éviter la fuite de données.
Métriques suivies : RMSE, MAE, MSE, MAPE, R^2 et skill vs persistance.

Pourquoi la baseline persistence est indispensable



Référence minimale

Le niveau du réservoir est très stable sur de longues périodes.

La persistence prédit : “la valeur future = la dernière valeur connue”.

Dans un contexte SCADA stable, cette baseline est naturellement forte.

Un modèle avancé n'est utile que s'il réduit clairement l'erreur.

Baseline RMSE



0,1446point de comparaison
obligatoire

Baseline MAE

0,0848

erreur moyenne faible

Résultats comparatifs : ARIMA bat la persistance



Modèle	RMSE	MAE	Skill
Persistence	0,1446	0,0848	0,0 %
ARIMA	0,1182	0,0703	+18,2 %
Auto-ARIMA	0,1194	0,0719	+17,4 %
XGBoost	0,2402	0,1435	-66,1 %
Linear local	0,6761	0,5408	-367,7 %
Kalman	3,4174	2,6026	-2275,6 %

Message clé : ARIMA améliore la baseline sur ce test.

Projet WADI — models_tests

Lire les courbes : où les modèles échouent



Les résidus complètent le RMSE : ils montrent les pics, les zones instables et les erreurs systématiques.

Conclusion et prochaines étapes

Statistique

ARIMA / auto-ARIMA

Rapide, robuste, très compétitif sur une série stable.

Supervisé

XGBoost

Utile avec variables exogènes et phases de variation, mais à améliorer.

Séquentiel

LSTM / GRU / TCN / Transformer

Prometteur sur fenêtres longues, plus coûteux à entraîner.

Prochaines étapes

Comparer plusieurs horizons : 5, 10 et 30 minutes.
Isoler les phases de transition plutôt que seulement les périodes stables.
Améliorer XGBoost : features retardées, capteurs physiques, tuning, SHAP.
Tester LSTM, GRU, TCN et Transformer sur des fenêtres temporelles plus longues.

Message final

Nous avons construit un pipeline de comparaison fiable. Sur cette cible très stable, ARIMA bat la persistance ; XGBoost et le deep learning restent intéressants pour exploiter les variables physiques et les phases de variation.

Table des matières

- 1 Analyse exploratoire des données
- 2 Protocole de validation et métriques
- 3 ARIMAs, LSTMs et TCN
- 4 Modèle XGBoost et Optuna
- 5 Comparaison de modèles
- 6 Limites et contraintes**

Limites des résultats

- Temps d'entraînement élevé et forte consommation mémoire :
 - Données très haute dimension
 - Grand nombre de variables exogènes
- D'où :
 - Faible nombre d'epochs possible
 - Exploration des hyperparamètres limitée
 - Aucune sélection de variables

Conséquence

Résultats à considérer comme préliminaires

Contraintes

- Données industrielles complexes
- Coordination d'équipe difficile
- Peu d'itérations possibles