

Prévision du Niveau du Réservoir

Projet WADI — Hackathon

Rapport de Projet

Un conflit sur le réservoir cible à considérer : 3_LT_001_PV ou 1_LT_001_PV

Contexte	Hackathon — Actemium
Dataset	WADI (Water Distribution) — 14 jours
Date	Avril 2026
Objectif	Forecasting multivarié du niveau réservoir (3_LT_001_PV)

Résultats clés du modèle XGBoost

Métrique	Valeur	Interprétation
RMSE	0.2973	Erreur en mètres (unité capteur)
MAE	0.1814	Erreur moyenne absolue
R ²	0.9987	99.87% de variance expliquée

Table des matières

1	Introduction et contexte	2
1.1	Présentation du projet	2
1.2	Architecture du système WADI	2
1.3	Structure du rapport	2
2	Description des données	3
2.1	Vue d'ensemble	3
2.2	Familles de variables	3
2.3	Variables cibles : les colonnes LT	4
3	Analyse Exploratoire des Données (EDA)	4
3.1	Méthodologie de nettoyage	4
3.1.1	Reconstruction de l'index temporel	4
3.1.2	Traitement des valeurs manquantes	5
3.1.3	Gestion des lignes dupliquées	5
3.1.4	Dimensions après nettoyage	5
3.2	Détection des valeurs aberrantes	5
3.3	Analyse des corrélations	6
3.3.1	Corrélations avec la variable cible	6
3.4	Analyse en Composantes Principales (ACP)	7
4	Modélisation — XGBoost avec optimisation bayésienne	7
4.1	Feature engineering temporel	7
4.2	Découpage chronologique des données	8
4.3	Optimisation des hyperparamètres — Optuna (TPE)	8
4.4	Résultats d'évaluation	9
4.4.1	Détection d'anomalies par seuillage des résidus	9
5	Discussion et perspectives	10
5.1	Bilan des travaux	10
5.2	Limites identifiées	10
5.3	Recommandations pour la suite	10
	Annexes	11

1 Introduction et contexte

1.1 Présentation du projet

Ce rapport présente les travaux réalisés dans le cadre du Hackathon sur le jeu de données **WADI** (*Water Distribution*). WADI est un banc d'essai industriel de distribution d'eau, instrumenté avec des capteurs physiques et des actionneurs (pompes, vannes) pilotés par un système SCADA (système de contrôle et d'acquisition de données).

L'**objectif principal** est de prédire le niveau du réservoir principal (3_LT_001_PV) à des horizons de 5, 10 et 30 minutes, afin d'anticiper les risques de débordement et d'optimiser les cycles de pompage.

1.2 Architecture du système WADI




FIGURE 1 – Architecture simplifiée du système WADI et identification de la zone cible

1.3 Structure du rapport

Ce rapport couvre deux volets complémentaires :

1. **Analyse exploratoire des données (EDA)** — nettoyage, compréhension des variables, détection d'anomalies structurelles, corrélations et réduction de dimensionnalité.
2. **Modélisation XGBoost** — feature engineering temporel, optimisation bayésienne des hyperparamètres, entraînement et évaluation sur données de test.

2 Description des données

2.1 Vue d'ensemble

TABLE 1 – Caractéristiques générales du jeu de données WADI

Caractéristique	Valeur
Nombre de lignes brutes	784 571
Nombre de colonnes brutes	130
Fréquence d'échantillonnage	1 mesure / seconde
Durée totale couverte	25/09/2017 au 07/10/2017 (13 jours)
Colonnes après nettoyage	121
Variables cibles (LT)	4 colonnes
Variable cible principale	3_LT_001_PV

Coupure dans les données

Une interruption de **3 jours** a été détectée entre le 29/09 et le 02/10/2017, correspondant à un arrêt physique du système SCADA (saut de 264 001 unités dans la colonne **Row**). Cette coupure a été documentée et prise en compte lors de la construction des séquences temporelles pour éviter de créer des fenêtres glissantes qui enjambent cette période.

2.2 Familles de variables

Le jeu de données contient plusieurs familles de capteurs et d'actionneurs, résumées dans le tableau suivant :

TABLE 2 – Résumé des familles de variables WADI

Préfixe	Nb colonnes	Description
AIT	18	Qualité de l'eau (pH, chlore, turbidité, conductivité)
FIT	5	Débits entrants/sortants des réservoirs
LT	4	Niveaux des réservoirs — variable(s) cible(s)
LS	17	Alarmes de niveau haut/bas (binaire)
MV	20	Commandes ON/OFF des vannes motorisées
FIC	–	Boucles PID de débit (mesure, consigne, commande)
PIC	–	Boucles PID de pression
PIT / DPIT	–	Pression locale et différentielle
FQ	–	Volume total d'eau écoulé (compteur cumulatif)
P_STATUS	–	État ON/OFF des pompes

2.3 Variables cibles : les colonnes LT

TABLE 3 – Statistiques descriptives des variables de niveau (LT)

Variable	Moyenne (m)	Écart-type	Min	Max
1_LT_001_PV	56.37	8.85	38.81	71.62
2_LT_001_PV	69.77	0.65	68.51	71.55
2_LT_002_PV	75.41	3.47	65.70	82.98
3_LT_001_PV	65.17	1.22	63.96	69.17

La variable 3_LT_001_PV (niveau du réservoir principal — Zone 3) est retenue comme **cible principale** pour la modélisation, conformément aux consignes du projet.

3 Analyse Exploratoire des Données (EDA)

3.1 Méthodologie de nettoyage

3.1.1 Reconstruction de l'index temporel

Point technique important — Format de la colonne Time

La colonne `Time` du fichier brut est au format `MM:SS` (minutes :secondes). Elle ne code que 3 600 valeurs distinctes par heure, sans information sur l'heure elle-même. La reconstruction naïve via `pd.to_datetime(Date + Time)` produit des centaines de milliers de doublons artificiels.

Solution adoptée : l'index temporel est reconstruit à partir de la colonne `Row` (compteur séquentiel en secondes depuis le démarrage) :

$$\text{Datetime} = 2017-09-25\ 00:00:00 + (\text{Row} - 1) \times 1\text{ s}$$

Cette approche donne un index sans aucun doublon et cohérent avec la fréquence d'échantillonnage réelle de **1 mesure/seconde**.

3.1.2 Traitement des valeurs manquantes

TABLE 4 – Bilan du traitement des valeurs manquantes

Colonne(s)	% manquants	Action
2_LS_001_AL, 2_LS_002_AL	100%	Suppression
2_P_001_STATUS, 2_P_002_STATUS	100%	Suppression
2_MCV_007_CD, 2_PIC_003_SP	Constantes	Suppression (variance nulle)
1_AIT_002_PV et autres	< 0.01%	Interpolation linéaire (limit=5 pas)
Variables catégorielles (STATUS, AL)	Résiduel	Forward-fill (dernier état connu)
Valeurs manquantes résiduelles		9 (lacunes > 5 s conservées)

3.1.3 Gestion des lignes dupliquées

Le dataset contient **580 452 lignes** où toutes les valeurs sont identiques à la ligne précédente (74% des données). Dans un contexte SCADA industriel, ce phénomène de « gel de capteur » est parfaitement normal : lorsqu’une grandeur physique ne varie pas, le système répète la dernière mesure.

Ces lignes **ne sont pas supprimées**, car leur suppression détruirait la régularité temporelle de la série à 1 Hz, indispensable au bon fonctionnement des modèles séquentiels (LSTM, GRU, fenêtres glissantes XGBoost).

3.1.4 Dimensions après nettoyage



3.2 Détection des valeurs aberrantes

La méthode de Tukey (règle $IQR \times 1.5$) a été appliquée sur l’ensemble des variables numériques. Les cinq variables présentant le plus fort taux de valeurs extrêmes sont :

TABLE 5 – Top 5 des variables avec le plus d’outliers (méthode IQR)

Variable	Nb outliers	% outliers
2_FIT_001_PV	190 228	24.25%
3_AIT_002_PV	179 875	22.93%
3_FIT_001_PV	165 392	21.08%
2_PIC_003_CO	148 348	18.91%
2_PIC_003_PV	144 116	18.37%

Interprétation industrielle

Dans un système de distribution d’eau, les valeurs extrêmes des débits (FIT) et pressions (PIC) correspondent typiquement à des **événements physiques réels** : ouverture/fermeture brusque d’une vanne, démarrage de pompe, transitoire hydraulique. Ces valeurs sont **conservées** dans le dataset et constituent au contraire des **signaux informatifs** pour prédire les variations du niveau.

3.3 Analyse des corrélations

3.3.1 Corrélations avec la variable cible

L’analyse de corrélation de Pearson entre toutes les variables numériques et la cible 3_LT_001_PV révèle les variables les plus informatives :

TABLE 6 – Top 7 variables corrélées avec 3_LT_001_PV

Variable	Pearson	Interprétation
2_FIC_401_CO	0.641	Commande PID débit zone 2→3
2_FIC_101_CO	0.529	Commande PID débit secondaire
3_FIT_001_PV	0.451	Débit entrant réservoir zone 3
2_MCV_301_CO	0.448	Commande vanne principale
2_MCV_601_CO	0.402	Commande vanne secondaire
2_FIT_002_PV	0.373	Débit sortant zone 2
3_AIT_005_PV	0.353	Qualité eau zone 3

Interprétation

Les commandes de vannes (MCV) et les boucles de régulation de débit (FIC) sont les variables les plus corrélées avec le niveau du réservoir — ce qui est physiquement cohérent : c’est bien le débit entrant contrôlé par les vannes qui fait monter ou descendre le niveau. Ces variables seront des features prioritaires pour la modélisation.

3.4 Analyse en Composantes Principales (ACP)

Une ACP a été réalisée sur les 63 variables numériques continues (hors colonnes LT) après standardisation, sur un sous-échantillon de 10% des données soit 78 457 observations.

TABLE 7 – Variance expliquée par les premières composantes principales

Composante	Variance expliquée (%)	Cumulé (%)
PC1	23.05	23.05
PC2	13.83	36.89
PC3	9.07	45.96
PC4	7.47	53.43
PC5	5.00	58.43
PC6	3.32	61.75
PC7	3.04	64.78
Pour atteindre 80% de variance		≈ 15 composantes

Conclusions de l'ACP

- Les 7 premières composantes n'expliquent que 65% de la variance — le jeu de données est **intrinsèquement de haute dimension**, sans structure basse-dimension dominante.
- La projection PC1/PC2 colorée par le niveau cible révèle une **structure non linéaire**, ce qui justifie l'usage de modèles non linéaires (XGBoost, LSTM) plutôt qu'une régression linéaire simple.
- **PC1** est principalement portée par les variables de débit et de commande de vanne
- cohérent avec les résultats de corrélation.

4 Modélisation — XGBoost avec optimisation bayésienne

4.1 Feature engineering temporel

XGBoost n'ayant pas de mémoire intrinsèque (contrairement aux LSTM), il est nécessaire d'encoder explicitement la dynamique temporelle dans les features.

Pour chaque lag $k \in \{1, 2, 3, 5, 10, 20, 60\}$ secondes :

$$\text{lag}_k(t) = x(t - k)$$

Pour des fenêtres glissantes de taille $w \in \{5, 10, 20, 60\}$ secondes, avec décalage d'un pas pour éviter toute fuite de données :

$$\text{roll_mean}_w(t) = \frac{1}{w} \sum_{i=1}^w x(t-i) \quad \text{roll_std}_w(t) = \text{std}(x(t-1), \dots, x(t-w))$$

Résultat : 131 features au total après suppression des lignes avec NA induits par les lags (60 lignes supprimées).

4.2 Découpage chronologique des données

Le split respecte **strictement l'ordre temporel** — aucun mélange aléatoire, pour éviter toute fuite de données future vers le passé.



TABLE 8 – Répartition des données après split temporel

Ensemble	Période	Lignes	Proportion
Train	25/09 → 04/10	142 839	70%
Validation	04/10 → 05/10	30 608	15%
Test	05/10 → 07/10	30 609	15%

4.3 Optimisation des hyperparamètres — Optuna (TPE)

L'optimisation bayésienne par algorithme TPE (*Tree-structured Parzen Estimator*) via Optuna a été utilisée à la place d'une grid search classique, pour explorer l'espace d'hyperparamètres de façon guidée.

TABLE 9 – Meilleurs hyperparamètres trouvés par Optuna

Hyperparamètre	Valeur optimisée	Rôle
max_depth	10	Profondeur maximale des arbres
eta (learning rate)	0.0112	Pas d'apprentissage
subsample	0.9996	Fraction de lignes par arbre
colsample_bytree	0.8366	Fraction de colonnes par arbre
gamma	4.808	Gain minimum pour créer un nœud
min_child_weight	1	Somme minimale de poids par feuille
lambda	≈ 0	Régularisation L2
alpha	≈ 0	Régularisation L1
tree_method	hist	Algorithme de construction

Early stopping (patience = 50 rounds) a été utilisé pendant l'entraînement pour stopper automatiquement si le RMSE de validation ne s'améliore plus, protégeant ainsi contre le sur-apprentissage sans fixer manuellement le nombre d'arbres.

4.4 Résultats d'évaluation

Performances du modèle XGBoost sur le set de test

Métrique	Valeur	Interprétation
RMSE	0.2973	Erreur typique de ± 0.30 m sur le niveau
MAE	0.1814	Erreur médiane de ≈ 18 cm
R ²	0.9987	99.87% de la variance du niveau expliquée

4.4.1 Détection d'anomalies par seuillage des résidus

Une méthode de détection d'anomalies a été dérivée des résidus du modèle : les instants où l'erreur absolue dépasse $\mu + 3\sigma$ (seuil = 0.888 m) sont flaggés comme potentiellement anormaux.

TABLE 10 – Résultats de détection d'anomalies

Seuil d'anomalie ($\mu + 3\sigma$)	0.8879
Nombre de pics d'erreur détectés	720
Couverture théorique	$\approx 99.7\%$ des erreurs normales sous le seuil

5 Discussion et perspectives

5.1 Bilan des travaux

TABLE 11 – Synthèse des travaux réalisés

Volet	Statut	Résultat
Chargement & index temporel	✓	Bug format MM:SS identifié et corrigé via Row
Nettoyage des données	✓	9 colonnes supprimées, 9 NA résiduels
Analyse des LT	✓	4 réservoirs analysés, profils journaliers caractérisés
Corrélations	✓	Variables FIC/MCV identifiées comme clés
ACP	✓	Structure haute dimension, non-linéarité confirmée
Feature engineering	✓	131 features (lags + rolling stats)
Optimisation hyperparamètres	✓	Optuna (TPE), 15 trials
Évaluation XGBoost	✓	$R^2 = 0.9987$, RMSE = 0.297
Analyse SHAP / importance	En cours	À compléter
Horizon 10 / 30 min	À faire	Extension du feature engineering
Modèle LSTM / GRU	À faire	Prévu par les autres membres du groupe

5.2 Limites identifiées

- **Coupure de 3 jours** : la coupure entre le 29/09 et le 02/10 réduit la durée effective d'entraînement et peut biaiser les rolling stats calculées au voisinage de la rupture. Des vérifications complémentaires sont nécessaires.
- **Variable cible unique** : la modélisation porte uniquement sur 3_LT_001_PV (horizon 1 pas). L'extension à des horizons de 10 et 30 minutes nécessite une reformulation du problème (*multi-step forecasting* ou *direct forecasting*).
- **Gel de capteur** : les 74% de lignes à valeurs identiques consécutives peuvent biaiser les métriques d'évaluation à la hausse — un modèle trivial de persistance obtiendrait déjà de bonnes performances sur ces instants.
- **Non-stationnarité potentielle** : l'analyse ACF/PACF n'a pas encore été réalisée. Des tests de stationnarité (ADF, KPSS) devraient être conduits avant la modélisation LSTM.

5.3 Recommandations pour la suite

1. **Baseline persistence** : calculer RMSE/MAE d'un modèle qui prédit $\hat{y}(t) = y(t - 1)$ comme référence, et s'assurer d'un gain d'au moins 20% (critère hackathon).

2. **Analyse SHAP** : produire les valeurs SHAP pour le modèle XGBoost afin d'identifier les variables les plus influentes et de valider la cohérence physique.
3. **Horizons multiples** : reformuler le problème pour prédire $y(t + N)$ avec $N \in \{5, 10, 30\}$ minutes (= 300, 600, 1800 pas à 1 Hz).
4. **Modèles DL** : évaluer LSTM/GRU en entrée des séries brutes sans feature engineering, pour comparer avec l'approche XGBoost + lags.

Annexes

A. Hyperparamètres complets du modèle XGBoost

```
{
  "lambda":          1.128e-08,
  "alpha":           2.176e-08,
  "max_depth":        10,
  "eta":              0.01117,
  "subsample":         0.9996,
  "colsample_bytree": 0.8366,
  "min_child_weight": 1,
  "gamma":            4.808,
  "objective":         "reg:squarederror",
  "eval_metric":       "rmse",
  "tree_method":       "hist",
  "seed":              42
}
```

B. Organisation du dépôt Git

```
hackathon-wadi/
data/
  WADI_14days_new.csv      # Données brutes
  WADI_clean.csv           # Données nettoyées (génééré par EDA)
notebooks/
  EDA_WADI.ipynb           # Analyse exploratoire (ce rapport)
  WADI_XGBoost.ipynb       # Modélisation XGBoost
artefacts/
  best_params.json         # Hyperparamètres Optuna
  metrics.json             # Métriques d'évaluation
rapport/
```

rapport_WADI.tex # Ce rapport

C. Glossaire

SCADA	Supervisory Control and Data Acquisition
RMSE	Root Mean Squared Error
MAE	Mean Absolute Error
ACP	Analyse en Composantes Principales
TPE	Tree-structured Parzen Estimator (algorithme Optuna)
IQR	Interquartile Range (méthode Tukey)
PV	Process Value — valeur mesurée par le capteur
SP	Setpoint — consigne du régulateur
CO	Controller Output — commande envoyée à l'actionneur